

Diagnosis 数据挖掘——实验报告

1、对 diagnosis 数据集进行处理，转换其形式

导入关联规则的 R 语言包：

```
install.packages('arules')
```

加载 arules 程序包：library(arules)

加载数据集：

把从网上下载的 diagnosis 数据(diagnosis.csv) 读入到 R 中。

```
x<-read.transactions("diagnosis.csv",format="basket",sep = "")
```

查看数据集相关的统计汇总信息，以及数据集本身

```
summary(x)
```

```
> summary(x)
transactions as itemMatrix in sparse format with
 120 rows (elements/itemsets/transactions) and
 53 columns (items) and a density of 0.03773585

most frequent items:
,no,yes,yes,no,yes,no,yes ,no,no,yes,yes,yes,yes,no ,no,yes,no,no,no,no,no ,no,no,no,no,no,no,no,no
      21                20                20                10
      ,no,no,yes,no,no,yes,no (Other)
      10                159

element (itemset/transaction) length distribution:
sizes
 2
120

      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
      2         2         2         2         2         2

includes extended item information - examples:
      labels
1  ,no,no,no,no,no,no,no,no
2  ,no,no,yes,no,no,yes,no
3  ,no,no,yes,yes,no,yes,no

> trans<-as(x,"transactions")
```

2、找出频繁项集

求频繁项集：

```
> #找出所有的频繁项集
> frequentsets<- eclat(trans,parameter=list(support=0.01,maxlen=10,minlen=2))
Eclat
```

parameter specification:

tidLists	support	minlen	maxlen	target	ext
FALSE	0.01	2	10	frequent itemsets	FALSE

algorithmic control:

sparse	sort	verbose
7	-2	TRUE

Absolute minimum support count: 1

查看求得的频繁项集 inspect(frequentsets)

```
> inspect(frequentsets)
```

	items	support
1	{,no,yes,yes,no,yes,no,yes,38,0}	0.01666667
2	{,no,no,yes,yes,yes,yes,no,36,8}	0.01666667
3	{,no,no,yes,yes,no,yes,no,37,6}	0.01666667
4	{,no,yes,no,no,no,no,no,36,7}	0.01666667
5	{,yes,yes,yes,yes,no,yes,yes,40,9}	0.01666667
6	{,no,yes,no,no,no,no,no,36,0}	0.01666667
7	{,no,yes,no,no,no,no,no,36,6}	0.01666667
8	{,no,no,yes,yes,yes,yes,no,36,6}	0.01666667
9	{,no,yes,yes,no,yes,no,yes,41,5}	0.01666667
10	{,no,no,yes,yes,no,yes,no,37,7}	0.01666667
11	{,no,no,yes,yes,no,yes,no,37,9}	0.01666667
12	{,yes,yes,yes,yes,no,yes,yes,40,4}	0.01666667
13	{,no,yes,no,no,no,no,no,37,5}	0.01666667
14	{,no,no,yes,no,no,yes,no,37,5}	0.01666667
15	{,no,no,yes,yes,yes,yes,no,37,0}	0.03333333
16	{,no,no,yes,yes,no,yes,no,37,0}	0.01666667
17	{,no,no,no,no,no,no,no,40,0}	0.01666667
18	{,yes,yes,no,yes,no,no,yes,40,0}	0.01666667
19	{,yes,yes,yes,yes,yes,yes,yes,40,0}	0.01666667

```

create itemset ...
set transactions ...[53 item(s), 120 transaction(s)] done [0.00s].
sorting and recoding items ... [37 item(s)] done [0.00s].
creating sparse bit matrix ... [37 row(s), 120 column(s)] done [0.00s].
writing ... [19 set(s)] done [0.00s].
Creating S4 object ... done [0.00s].

```

3、导出关联规则，计算其支持度和置信度

用 apriori 求关联规则，并查看相关的统计汇总信息

```

> #找出所有的关联规则
> rules <- apriori(trans,parameter=list(support=0.01,confidence=0.4,minlen=2))
Apriori

Parameter specification:
 confidence minval smax arem aval originalSupport support minlen maxlen target ext
      0.4      0.1    1 none FALSE          TRUE    0.01      2    10 rules FALSE

Algorithmic control:
 filter tree heap memopt load sort verbose
    0.1 TRUE TRUE  FALSE TRUE    2    TRUE

Absolute minimum support count: 1

set item appearances ...[0 item(s)] done [0.00s].
set transactions ...[53 item(s), 120 transaction(s)] done [0.00s].
sorting and recoding items ... [37 item(s)] done [0.00s].
creating transaction tree ... done [0.00s].
checking subsets of size 1 2 done [0.00s].
writing ... [13 rule(s)] done [0.00s].
creating S4 object ... done [0.00s].

> summary(rules)
set of 13 rules

rule length distribution (lhs + rhs):sizes
 2
13

      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
       2       2       2       2       2       2

summary of quality measures:
      support      confidence      lift
Min.   :0.01667  Min.   :0.4000  Min.   :2.857
1st Qu.:0.01667  1st Qu.:0.5000  1st Qu.:3.000
Median :0.01667  Median :0.5000  Median :4.800
Mean   :0.01795  Mean   :0.6128  Mean   :4.859
3rd Qu.:0.01667  3rd Qu.:0.6667  3rd Qu.:6.000
Max.   :0.03333  Max.   :1.0000  Max.   :8.000

mining info:
      data ntransactions support confidence
trans          120      0.01      0.4

```

> #查看所有规则

> inspect(rules)

	lhs	rhs	support	confidence	lift
1	{36,8}	=> {,no,no,yes,yes,yes,yes,no}	0.01666667	1.0000000	6.000000
2	{38,0}	=> {,no,yes,yes,no,yes,no,yes}	0.01666667	1.0000000	5.714286
3	{36,0}	=> {,no,yes,no,no,no,no,no}	0.01666667	0.6666667	4.000000
4	{40,9}	=> {,yes,yes,yes,yes,no,yes,yes}	0.01666667	0.6666667	8.000000
5	{36,7}	=> {,no,yes,no,no,no,no,no}	0.01666667	0.6666667	4.000000
6	{37,6}	=> {,no,no,yes,yes,no,yes,no}	0.01666667	0.6666667	8.000000
7	{37,7}	=> {,no,no,yes,yes,no,yes,no}	0.01666667	0.5000000	6.000000
8	{41,5}	=> {,no,yes,yes,no,yes,no,yes}	0.01666667	0.5000000	2.857143
9	{36,6}	=> {,no,yes,no,no,no,no,no}	0.01666667	0.5000000	3.000000
10	{36,6}	=> {,no,no,yes,yes,yes,yes,no}	0.01666667	0.5000000	3.000000
11	{40,4}	=> {,yes,yes,yes,yes,no,yes,yes}	0.01666667	0.4000000	4.800000
12	{37,9}	=> {,no,no,yes,yes,no,yes,no}	0.01666667	0.4000000	4.800000
13	{37,0}	=> {,no,no,yes,yes,yes,yes,no}	0.03333333	0.5000000	3.000000

> #按支持度查看前6条规则

> inspect(sort(rules,by="support")[1:6])

	lhs	rhs	support	confidence	lift
13	{37,0}	=> {,no,no,yes,yes,yes,yes,no}	0.03333333	0.5000000	3.000000
1	{36,8}	=> {,no,no,yes,yes,yes,yes,no}	0.01666667	1.0000000	6.000000
2	{38,0}	=> {,no,yes,yes,no,yes,no,yes}	0.01666667	1.0000000	5.714286
3	{36,0}	=> {,no,yes,no,no,no,no,no}	0.01666667	0.6666667	4.000000
4	{40,9}	=> {,yes,yes,yes,yes,no,yes,yes}	0.01666667	0.6666667	8.000000
5	{36,7}	=> {,no,yes,no,no,no,no,no}	0.01666667	0.6666667	4.000000

> #按置信度查看前6条规则

> inspect(sort(rules,by="confidence")[1:6])

	lhs	rhs	support	confidence	lift
1	{36,8}	=> {,no,no,yes,yes,yes,yes,no}	0.01666667	1.0000000	6.000000
2	{38,0}	=> {,no,yes,yes,no,yes,no,yes}	0.01666667	1.0000000	5.714286
3	{36,0}	=> {,no,yes,no,no,no,no,no}	0.01666667	0.6666667	4.000000
4	{40,9}	=> {,yes,yes,yes,yes,no,yes,yes}	0.01666667	0.6666667	8.000000
5	{36,7}	=> {,no,yes,no,no,no,no,no}	0.01666667	0.6666667	4.000000
6	{37,6}	=> {,no,no,yes,yes,no,yes,no}	0.01666667	0.6666667	8.000000

4、删除冗余的规则

```
> #删除冗余规则
> subset.matrix<-is.subset(rules,rules)

> subset.matrix[lower.tri(subset.matrix,diag = T)]<-NA

> redundant<-colSums(subset.matrix,na.rm = T)>=1

> which(redundant)
named integer(0)

> rules.pruned<-rules[!redundant]

> inspect(rules.pruned)
```

	lhs	rhs	support	confidence	lift
1	{36,8}	=> {,no,no,yes,yes,yes,yes,no}	0.01666667	1.0000000	6.000000
2	{38,0}	=> {,no,yes,yes,no,yes,no,yes}	0.01666667	1.0000000	5.714286
3	{36,0}	=> {,no,yes,no,no,no,no,no}	0.01666667	0.6666667	4.000000
4	{40,9}	=> {,yes,yes,yes,yes,no,yes,yes}	0.01666667	0.6666667	8.000000
5	{36,7}	=> {,no,yes,no,no,no,no,no}	0.01666667	0.6666667	4.000000
6	{37,6}	=> {,no,no,yes,yes,no,yes,no}	0.01666667	0.6666667	8.000000
7	{37,7}	=> {,no,no,yes,yes,no,yes,no}	0.01666667	0.5000000	6.000000
8	{41,5}	=> {,no,yes,yes,no,yes,no,yes}	0.01666667	0.5000000	2.857143
9	{36,6}	=> {,no,yes,no,no,no,no,no}	0.01666667	0.5000000	3.000000
10	{36,6}	=> {,no,no,yes,yes,yes,yes,no}	0.01666667	0.5000000	3.000000
11	{40,4}	=> {,yes,yes,yes,yes,no,yes,yes}	0.01666667	0.4000000	4.800000
12	{37,9}	=> {,no,no,yes,yes,no,yes,no}	0.01666667	0.4000000	4.800000
13	{37,0}	=> {,no,no,yes,yes,yes,yes,no}	0.03333333	0.5000000	3.000000

5、对规则进行评价，可使用 Lift，也可以使用教材中所提及的其它指标

```
> #根据lift排序
> sorted_lift<-sort(rules,by='lift')

> inspect(sorted_lift)
```

	lhs	rhs	support	confidence	lift
4	{40,9}	=> {,yes,yes,yes,yes,no,yes,yes}	0.01666667	0.6666667	8.000000
6	{37,6}	=> {,no,no,yes,yes,no,yes,no}	0.01666667	0.6666667	8.000000
1	{36,8}	=> {,no,no,yes,yes,yes,yes,no}	0.01666667	1.0000000	6.000000
7	{37,7}	=> {,no,no,yes,yes,no,yes,no}	0.01666667	0.5000000	6.000000
2	{38,0}	=> {,no,yes,yes,no,yes,no,yes}	0.01666667	1.0000000	5.714286
11	{40,4}	=> {,yes,yes,yes,yes,no,yes,yes}	0.01666667	0.4000000	4.800000
12	{37,9}	=> {,no,no,yes,yes,no,yes,no}	0.01666667	0.4000000	4.800000
3	{36,0}	=> {,no,yes,no,no,no,no,no}	0.01666667	0.6666667	4.000000
5	{36,7}	=> {,no,yes,no,no,no,no,no}	0.01666667	0.6666667	4.000000
9	{36,6}	=> {,no,yes,no,no,no,no,no}	0.01666667	0.5000000	3.000000
10	{36,6}	=> {,no,no,yes,yes,yes,yes,no}	0.01666667	0.5000000	3.000000
13	{37,0}	=> {,no,no,yes,yes,yes,yes,no}	0.03333333	0.5000000	3.000000
8	{41,5}	=> {,no,yes,yes,no,yes,no,yes}	0.01666667	0.5000000	2.857143


6、使用可视化技术，对规则进行展示。

```
> #可视化
> #install.packages(pkgs="arulesViz")
> library(arulesViz)

> plot(rules)

> plot(rules,method="graph",control=list(type="items"))

> plot(rules,method="paracoord",control=list(reorder=TRUE))
```

Scatter plot for 13 rules



实验说明：

实验环境：使用 R 软件的 Windows 版本，运行下载文件 R-3.3.0-win.exe。

安装实验中需要的包 `arules` 和 `arulesViz`。